AgroVision_AI

Clasificación de enfermedades en hojas de tomate mediante aprendizaje profundo

Proyecto de Deep Learning — Taller ABP

Curso: DEEP LEARNING
Estudiante: Juan Pablo Tejada Márquez
Programa: Ingeniería en Analítica de Datos

Fundación Universitaria Católica del Norte
Fecha: 15 de octubre de 2026

Repositorio:

https://github.com/juanpablomarquez10-spec/AgroVision_AI

Resumen

El presente proyecto desarrolla AgroVision_AI, una propuesta de inteligencia artificial orientada a la clasificación de enfermedades en hojas de tomate mediante técnicas de aprendizaje profundo (*Deep Learning*). El propósito es construir y evaluar modelos capaces de identificar tres categorías: tomate con tizón temprano (*Early Blight*), tomate con tizón tardío (*Late Blight*) y hoja saludable (*Healthy*).

Para el desarrollo se utilizó un conjunto de 1.495 imágenes, distribuido en entrenamiento, validación y prueba. Se implementaron dos enfoques: una red neuronal convolucional construida desde cero (CNN) y un modelo MobileNetV2 con pesos preentrenados en ImageNet, utilizando aprendizaje por transferencia (*Transfer Learning*).

Los modelos se evaluaron mediante exactitud (*accuracy*), pérdida (*loss*), precisión, exhaustividad (*recall*) y puntuación F1. Los resultados obtenidos en el conjunto de prueba muestran que la CNN alcanzó una exactitud del 76,44 %, mientras que MobileNetV2 obtuvo un 93,33 %. Esto representa una diferencia de 16,89 puntos porcentuales a favor del modelo preentrenado.

Finalmente, se desarrolló una interfaz que permite cargar una imagen de una hoja de tomate y visualizar la clase predicha por MobileNetV2. El proyecto constituye un prototipo académico para explorar el uso del aprendizaje profundo en la clasificación visual de enfermedades vegetales. Sus predicciones son experimentales y requieren validación adicional antes de considerar su utilización en condiciones agrícolas reales.

Palabras clave: aprendizaje profundo, redes neuronales convolucionales, MobileNetV2, aprendizaje por transferencia, clasificación de imágenes, enfermedades del tomate.

1. Introducción

La inteligencia artificial y el aprendizaje profundo se han convertido en herramientas importantes para el análisis automatizado de imágenes. Estas tecnologías permiten desarrollar sistemas capaces de reconocer patrones visuales y utilizarlos para realizar tareas de clasificación en diferentes campos, entre ellos la agricultura.

En los cultivos de tomate, las enfermedades foliares pueden afectar el desarrollo de las plantas y la calidad de la producción. La identificación visual de síntomas constituye una actividad importante para el seguimiento de los cultivos, aunque puede presentar dificultades cuando los síntomas son similares o las condiciones de observación no son adecuadas.

En este contexto, el proyecto AgroVision_AI propone desarrollar un sistema experimental de clasificación de imágenes que permita reconocer hojas de tomate con tizón temprano, tizón tardío o sin enfermedad aparente. Para ello, se emplean técnicas de aprendizaje profundo y se comparan dos arquitecturas con características diferentes.

La primera arquitectura corresponde a una red neuronal convolucional desarrollada desde cero. La segunda utiliza MobileNetV2, una arquitectura preentrenada que permite aprovechar características visuales aprendidas previamente. La comparación permite analizar las diferencias de desempeño entre ambos enfoques sobre un mismo conjunto de prueba.

Además del entrenamiento y la evaluación de los modelos, se implementó una interfaz para facilitar la interacción con el sistema. De esta manera, el proyecto integra preparación de datos, construcción de modelos, evaluación experimental, almacenamiento de evidencias y presentación de predicciones.

2. Planteamiento del problema

La identificación de enfermedades en hojas de tomate requiere reconocer características visuales como manchas, cambios de coloración y alteraciones en el tejido foliar. La clasificación basada únicamente en observación visual puede resultar compleja cuando diferentes enfermedades presentan síntomas parecidos.

El aprendizaje profundo ofrece una alternativa para automatizar parte de este proceso mediante modelos entrenados con imágenes etiquetadas. Sin embargo, desarrollar un clasificador no consiste solamente en obtener una predicción: también es necesario evaluar su desempeño, identificar posibles errores y determinar si los resultados son suficientemente consistentes para el propósito planteado.

Por esta razón, el problema abordado consiste en determinar si un modelo de aprendizaje profundo puede clasificar imágenes de hojas de tomate en tres categorías y qué diferencias de desempeño se presentan al comparar una CNN construida desde cero con una arquitectura preentrenada como MobileNetV2.

El desarrollo también debe considerar aspectos como la distribución de los datos, la separación entre entrenamiento y prueba, la reproducibilidad del proceso y la interpretación de las métricas obtenidas.

2.1. Pregunta de investigación

¿En qué medida una red neuronal convolucional construida desde cero y un modelo MobileNetV2 con aprendizaje por transferencia permiten clasificar imágenes de hojas de tomate en las categorías tizón temprano, tizón tardío y saludable?

3. Justificación

El desarrollo de AgroVision_AI se justifica por la oportunidad de aplicar técnicas de aprendizaje profundo a un problema relacionado con el análisis de imágenes agrícolas.

Desde el punto de vista académico, el proyecto permite integrar conocimientos de preparación de datos, redes neuronales, entrenamiento supervisado, evaluación de modelos y desarrollo de aplicaciones. También facilita la comparación experimental entre una arquitectura diseñada desde cero y otra que aprovecha pesos preentrenados.

Desde el punto de vista técnico, el proyecto permite estudiar cómo la elección de una arquitectura influye en el desempeño de un clasificador. La comparación entre modelos se realiza con el mismo conjunto de prueba, lo que proporciona una base para analizar sus resultados bajo condiciones de evaluación comunes.

Desde una perspectiva práctica, la interfaz desarrollada permite probar el sistema con imágenes seleccionadas por el usuario. Aunque el prototipo no sustituye el diagnóstico profesional ni demuestra por sí solo su efectividad en campo, constituye una base para futuras investigaciones sobre clasificación automática de enfermedades vegetales.

Finalmente, la organización del código, los modelos entrenados y las evidencias facilita la revisión del proceso y la verificación de los resultados obtenidos.

4. Objetivos

4.1. Objetivo general

Desarrollar y evaluar un sistema experimental de clasificación de enfermedades en hojas de tomate mediante aprendizaje profundo, comparando una red neuronal convolucional construida desde cero con un modelo MobileNetV2 preentrenado.

4.2. Objetivos específicos

1. Preparar y organizar un conjunto de imágenes de hojas de tomate para las etapas de entrenamiento, validación y prueba.
2. Diseñar e implementar una red neuronal convolucional capaz de clasificar las imágenes en tres categorías.
3. Implementar MobileNetV2 mediante aprendizaje por transferencia, utilizando una base preentrenada y una capa de clasificación adaptada al problema.
4. Evaluar ambos modelos utilizando métricas de clasificación y matrices de confusión.
5. Comparar los resultados obtenidos para identificar diferencias de desempeño y posibles errores de clasificación.
6. Desarrollar una interfaz que permita cargar imágenes y visualizar las predicciones del modelo seleccionado.
7. Documentar el proceso y conservar evidencias que permitan revisar los resultados experimentales.

5. Marco teórico

5.1. Aprendizaje profundo

El aprendizaje profundo es una rama del aprendizaje automático que utiliza redes neuronales con múltiples capas para aprender representaciones de los datos. En imágenes, estas representaciones permiten identificar patrones visuales que pueden resultar relevantes para distinguir entre diferentes categorías.

Durante el entrenamiento, el modelo ajusta sus parámetros para reducir una función de pérdida que cuantifica la diferencia entre las predicciones y las etiquetas reales.

5.2. Redes neuronales convolucionales

Las redes neuronales convolucionales (CNN) son arquitecturas utilizadas ampliamente en tareas de visión por computador. Las capas convolucionales aplican filtros sobre la imagen para detectar patrones locales, mientras que las operaciones de agrupamiento reducen las dimensiones espaciales de las representaciones.

En una tarea de clasificación, las características extraídas por las capas iniciales y profundas se utilizan posteriormente para calcular una probabilidad asociada a cada clase.

En este proyecto, la CNN construida desde cero utiliza capas convolucionales con 32, 64 y 128 filtros, seguidas de agrupamiento global, regularización mediante *Dropout* y capas densas para producir la clasificación final.

5.3. Aprendizaje por transferencia

El aprendizaje por transferencia consiste en aprovechar un modelo entrenado previamente para resolver una nueva tarea. En lugar de aprender todas las características desde cero, se utiliza una base que ya ha aprendido representaciones visuales a partir de un conjunto de datos amplio.

Esta estrategia puede ser especialmente útil cuando el conjunto de datos disponible para la nueva tarea es limitado.

En AgroVision_AI se emplea MobileNetV2 con pesos preentrenados en ImageNet. La base convolucional se mantiene congelada y se agrega una capa de clasificación para las tres categorías de hojas de tomate.

5.4. MobileNetV2

MobileNetV2 es una arquitectura de redes neuronales diseñada para obtener representaciones visuales con un costo computacional relativamente reducido. Su diseño incorpora convoluciones separables en profundidad y bloques invertidos residuales.

Estas características hacen que sea una alternativa interesante para experimentar con clasificación de imágenes cuando se busca aprovechar un modelo preentrenado sin entrenar desde cero todos sus parámetros.

5.5. Métricas de evaluación

Para analizar los modelos se utilizan las siguientes métricas:

- Exactitud (*accuracy*): proporción total de predicciones correctas sobre el número de ejemplos evaluados.
- Pérdida (*loss*): valor de la función utilizada para medir el error de las predicciones.
- Precisión (*precision*): proporción de predicciones positivas de una clase que corresponden efectivamente a esa clase.
- Exhaustividad (*recall*): proporción de ejemplos reales de una clase que el modelo consigue identificar correctamente.
- Puntuación F1: media armónica entre precisión y exhaustividad.
- Matriz de confusión: tabla que permite comparar las clases reales con las clases predichas y observar los errores de clasificación.

La exactitud ofrece una visión general del desempeño, mientras que las métricas por clase permiten identificar categorías en las que el modelo presenta mayores dificultades.

6. Descripción del conjunto de datos

El proyecto utiliza un conjunto de 1.495 imágenes de hojas de tomate distribuidas en tres categorías: tizón temprano, tizón tardío y saludable.

Las imágenes se organizaron en tres subconjuntos: entrenamiento, validación y prueba. El conjunto de entrenamiento se utilizó para ajustar los parámetros de los modelos; el de validación, para supervisar el comportamiento durante el entrenamiento; y el de prueba, para evaluar el desempeño final

6.1. Distribución de las imágenes

Categoría	Entrenamiento	Validación	Prueba	Total
Tizón temprano (*Early Blight*)	346	74	75	495
Tizón tardío (*Late Blight*)	350	75	75	500
Saludable (*Healthy*)	350	75	75	500
Total	**1.046**	**224**	**225**	**1.495**

La distribución del conjunto de prueba es equilibrada, con 75 imágenes por categoría. Esto facilita la comparación de los resultados entre clases sin que una categoría tenga una representación mayoritaria en dicho subconjunto.

Las imágenes se procesaron con un tamaño de 180 × 180 píxeles y se utilizó un tamaño de lote de 32 imágenes. Para favorecer la reproducibilidad, se estableció la semilla aleatoria 42 en la configuración del proceso.

Fuente del conjunto de datos: Se utilizó un conjunto de imágenes de hojas de tomate organizado en tres categorías: tizón temprano (*Early Blight*), tizón tardío (*Late Blight*) y hojas saludables (*Healthy*). Las imágenes se distribuyeron en conjuntos de entrenamiento, validación y prueba para desarrollar y evaluar los modelos de aprendizaje profundo del proyecto AgroVision_AI. La fuente original del conjunto de datos está pendiente de verificación.

6.2. Preprocesamiento y aumento de datos

Las imágenes se cargaron mediante las herramientas de procesamiento de imágenes de TensorFlow y Keras. Para la CNN se utilizó una capa de reescalado que transforma los valores de los píxeles al intervalo entre 0 y 1.

Durante el entrenamiento de la CNN se aplicaron transformaciones de aumento de datos, específicamente volteo horizontal aleatorio, rotación aleatoria y acercamiento aleatorio. Estas operaciones permiten generar variaciones de las imágenes de entrenamiento y pueden contribuir a reducir la dependencia del modelo respecto de orientaciones o encuadres específicos.

Para MobileNetV2 se utilizó un reescalado al intervalo entre -1 y 1, compatible con el procesamiento habitual de esta arquitectura preentrenada.

El aumento de datos se aplica durante el entrenamiento y no debe confundirse con la creación de nuevas imágenes independientes para los conjuntos de validación o prueba.

7. Metodología

El desarrollo de AgroVision_AI se organizó en las siguientes etapas:

1. **Preparación de los datos:** organización de las imágenes en categorías y subconjuntos de entrenamiento, validación y prueba.
2. **Preprocesamiento:** redimensionamiento de las imágenes y normalización de los valores de los píxeles.

3. **Construcción de la CNN:** implementación de una arquitectura convolucional desde cero.
4. **Implementación de MobileNetV2:** adaptación de un modelo preentrenado mediante aprendizaje por transferencia.
5. **Entrenamiento:** ajuste de los modelos con los datos de entrenamiento y seguimiento del desempeño en validación.
6. **Evaluación:** cálculo de métricas sobre el conjunto de prueba y generación de matrices de confusión.
7. **Comparación:** análisis de los resultados de ambos modelos utilizando las mismas categorías y el mismo conjunto de prueba.
8. **Desarrollo de la interfaz:** integración de MobileNetV2 en una aplicación que permite cargar imágenes y consultar las predicciones.
9. **Documentación:** almacenamiento de métricas, historiales, gráficas, matrices de confusión y capturas de funcionamiento.

Para controlar el entrenamiento se utilizaron mecanismos de detención temprana (*EarlyStopping*) y guardado del mejor modelo (*ModelCheckpoint*), monitorizando la pérdida de validación. Estas estrategias ayudan a conservar los pesos asociados al mejor desempeño de validación y a evitar entrenamientos innecesariamente prolongados.

8. Diseño e implementación de la CNN

8.1. Arquitectura

La primera propuesta consiste en una red neuronal convolucional construida desde cero. Su propósito es establecer una referencia experimental para comparar el desempeño de una arquitectura diseñada específicamente para el proyecto frente a una arquitectura preentrenada.

La red recibe imágenes RGB de 180 × 180 píxeles. Después de la normalización, las imágenes pasan por tres bloques convolucionales, cada uno seguido de una operación de agrupamiento máximo.

Posteriormente, se utiliza agrupamiento promedio global para resumir las características extraídas. Se incorpora una capa *Dropout* con una tasa de 0,30 y una capa densa de 64 neuronas. La capa final contiene tres neuronas con activación *softmax*, una por cada categoría.

Componente	Configuración
Entrada	Imagen RGB de 180 × 180 píxeles
Normalización	Reescalado por 1/255
Bloque convolucional 1	32 filtros, kernel 3 × 3, ReLU
Agrupamiento 1	MaxPooling2D
Bloque convolucional 2	64 filtros, kernel 3 × 3, ReLU

Agrupamiento 2	MaxPooling2D
Bloque convolucional 3	128 filtros, kernel 3 × 3, ReLU
Agrupamiento 3	MaxPooling2D
Extracción final	GlobalAveragePooling2D
Regularización	Dropout de 0,30
Capa densa	64 neuronas, ReLU
Salida	3 neuronas, Softmax

8.2. Configuración del entrenamiento

La CNN se configuró con un máximo de 20 épocas, lotes de 32 imágenes y el optimizador Adam. La función de pérdida fue *sparse categorical crossentropy*, apropiada para clasificación multiclase con etiquetas enteras.

La métrica principal registrada durante el entrenamiento fue la exactitud. También se guardaron el historial del entrenamiento, las métricas de prueba, las curvas y la matriz de confusión.

El modelo entrenado se guardó en la ruta modelos/cnn_tomate.keras, mientras que las evidencias se almacenaron en la carpeta evidencias/CNN.

8.3. Curvas de entrenamiento de la CNN

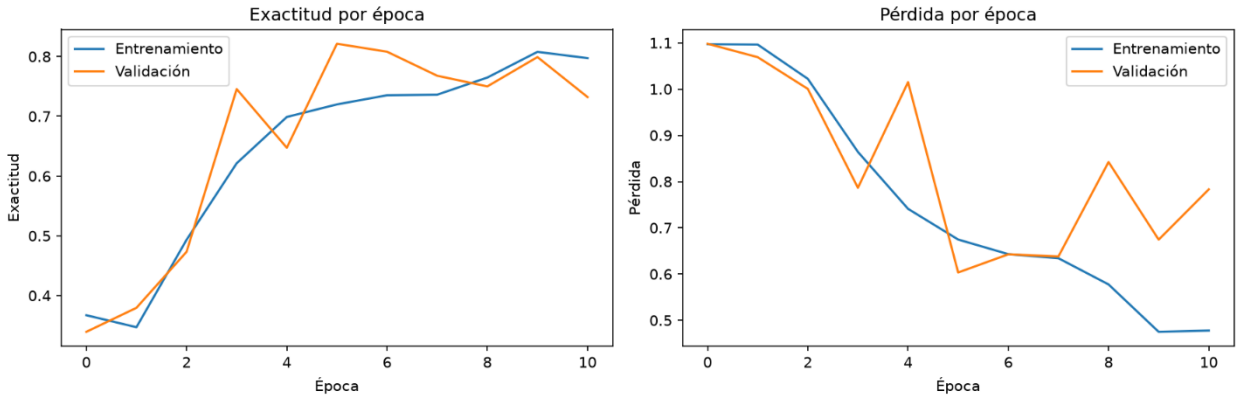


Figura 1. Curvas de exactitud y pérdida de entrenamiento y validación de la CNN.

Fuente: elaboración propia a partir del entrenamiento de AgroVision_AI.

Las curvas permiten observar cómo evoluciona el aprendizaje a lo largo de las épocas. La comparación entre las métricas de entrenamiento y validación ayuda a identificar variaciones en la capacidad de generalización del modelo.

En el historial registrado, la mejor pérdida de validación fue aproximadamente 0,6034 en la época 6, con una exactitud de validación del 82,14 %. En épocas posteriores se observan variaciones en las métricas de

validación, por lo que resulta importante analizar el comportamiento del modelo y no limitarse a considerar la exactitud de entrenamiento.

8.4. Matriz de confusión de la CNN

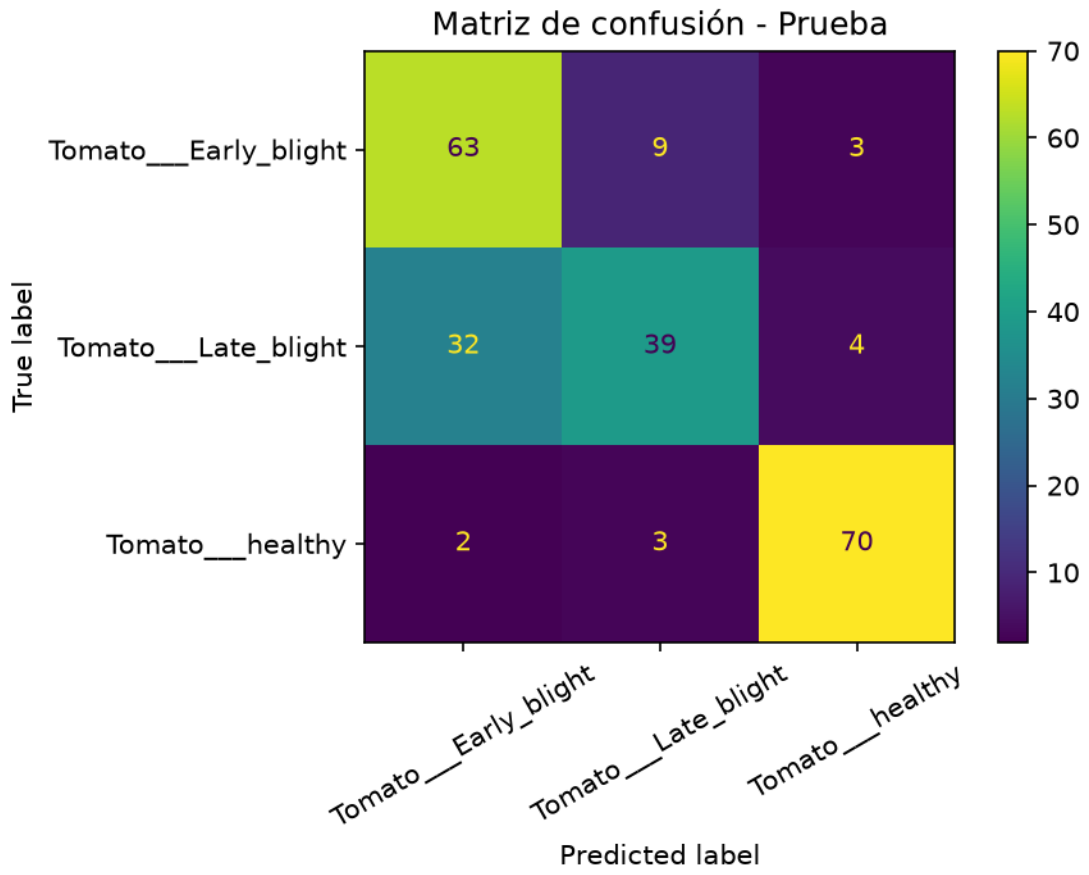


Figura 2. Matriz de confusión de la CNN sobre el conjunto de prueba.
Fuente: elaboración propia a partir de la evaluación de AgroVision_AI.

La matriz de confusión permite identificar cuáles categorías son reconocidas con mayor precisión y entre cuáles se presentan confusiones. Este análisis complementa la exactitud global y ayuda a comprender los errores del modelo.

9. Diseño e implementación de MobileNetV2

9.1. Arquitectura

La segunda propuesta utiliza MobileNetV2 con pesos preentrenados en ImageNet. A diferencia de la CNN anterior, esta arquitectura aprovecha características visuales aprendidas durante un entrenamiento previo con un conjunto amplio de imágenes.

Para adaptar el modelo a la clasificación de hojas de tomate, se excluyó la capa de clasificación original mediante include_top=False. La base convolucional se mantuvo congelada, por lo que sus pesos no se actualizaron durante el entrenamiento de este proyecto.

Sobre la base se incorporaron una capa de agrupamiento promedio global, una capa *Dropout* con una tasa de 0,25 y una capa final de tres neuronas con activación *softmax*.

Componente	Configuración
Entrada	Imagen RGB de 180 × 180 píxeles
Preprocesamiento	Reescalado al intervalo -1 a 1
Base convolucional	MobileNetV2 preentrenada en ImageNet
Capa clasificadora original	Excluida
Entrenabilidad de la base	Congelada
Extracción final	GlobalAveragePooling2D
Regularización	Dropout de 0,25
Salida	3 neuronas, Softmax

9.2. Configuración del entrenamiento

MobileNetV2 se entrenó durante un máximo de 15 épocas, con lotes de 32 imágenes y una tasa de aprendizaje de 0,001 para el optimizador Adam.

Se utilizó *sparse categorical crossentropy* como función de pérdida y exactitud como métrica de seguimiento. También se configuraron mecanismos de detención temprana y guardado del mejor modelo, monitorizando la pérdida de validación.

El modelo se guardó en modelos/mobilenetv2_tomate.keras. Sus métricas, historiales, curvas y matriz de confusión se almacenaron en evidencias/MobileNetV2.

9.3. Curvas de entrenamiento de MobileNetV2

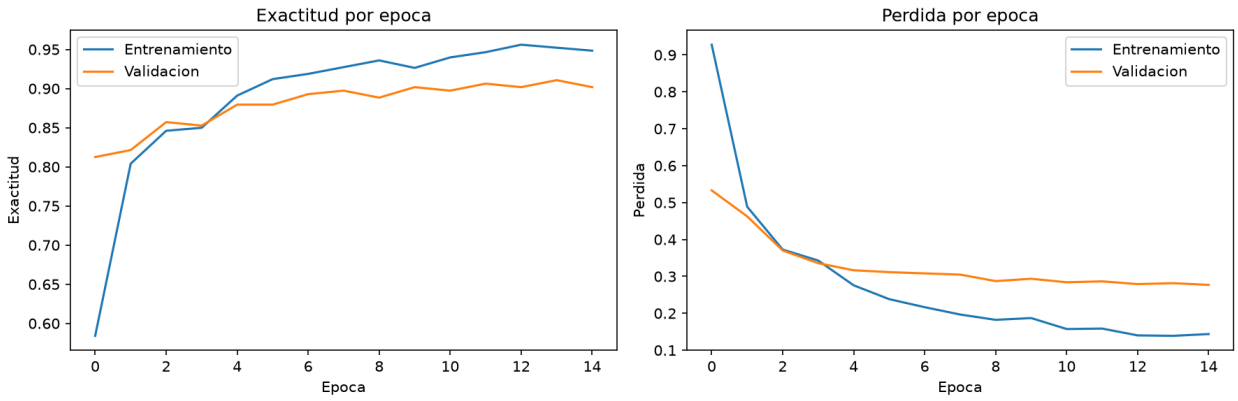


Figura 3. Curvas de exactitud y pérdida de entrenamiento y validación de MobileNetV2.
Fuente: elaboración propia a partir del entrenamiento de AgroVision_AI.

El historial muestra que el modelo alcanzó una exactitud de entrenamiento aproximada del 94,84 % y una exactitud de validación del 90,18 % en la época 15. La pérdida de validación registrada para esa época fue aproximadamente 0,2770.

Estos valores describen el comportamiento durante el entrenamiento y la validación. No deben confundirse con las métricas finales del conjunto de prueba, que se presentan en la sección de resultados.

9.4. Matriz de confusión de MobileNetV2

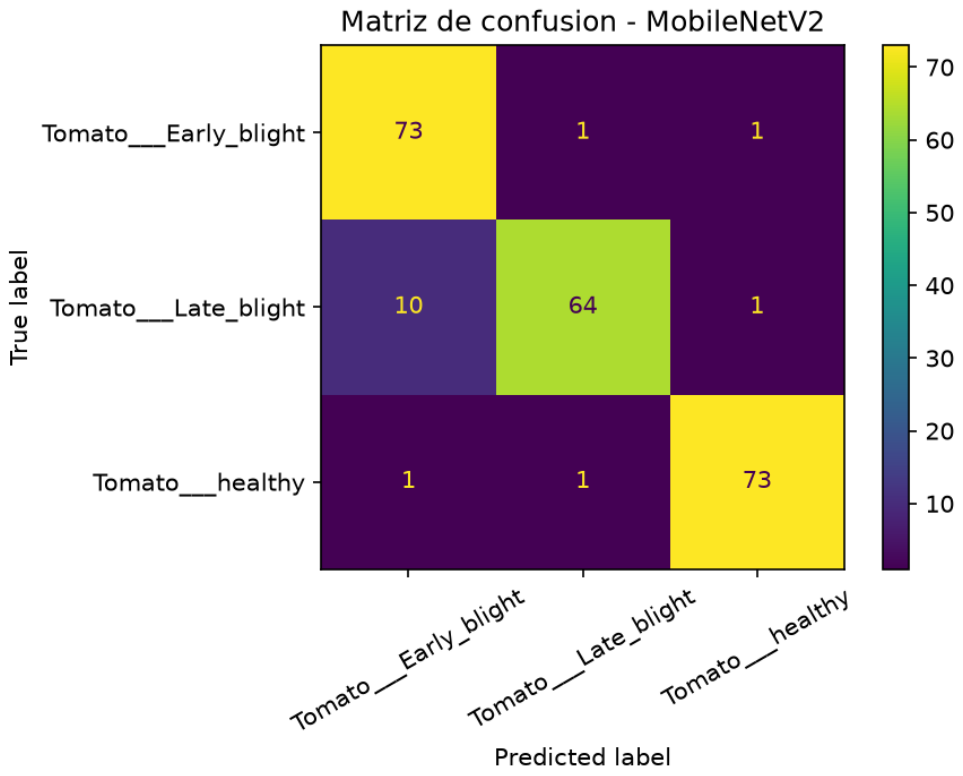


Figura 4. Matriz de confusión de MobileNetV2 sobre el conjunto de prueba.
Fuente: elaboración propia a partir de la evaluación de AgroVision_AI.

La matriz permite examinar la correspondencia entre las etiquetas reales y las predicciones del modelo. Su análisis resulta especialmente importante para identificar errores entre el tizón temprano y el tizón tardío, así como para comprobar el reconocimiento de las hojas saludables.

10. Resultados experimentales

10.1. Comparación general

Los modelos se evaluaron sobre el mismo conjunto de prueba, compuesto por 225 imágenes: 75 correspondientes a tizón temprano, 75 a tizón tardío y 75 a hojas saludables.

La siguiente tabla presenta los resultados registrados en los archivos de métricas del proyecto.

Métrica	CNN desde cero	MobileNetV2

Exactitud	76,44 %	93,33 %
Pérdida	0,5803	0,2107
Precisión macro	77,44 %	93,74 %
Recall macro	76,44 %	93,33 %
F1 macro	75,76 %	93,31 %
Imágenes de prueba	225	225

Fuente: archivos evidencias/CNN/metricas_prueba.json, evidencias/MobileNetV2/metricas_prueba.json y evidencias/comparacion_modelos.csv.

Los resultados muestran una diferencia de 16,89 puntos porcentuales en exactitud a favor de MobileNetV2. En el conjunto de prueba, la CNN clasificó correctamente 172 de las 225 imágenes, mientras que MobileNetV2 clasificó correctamente 210.

Además, MobileNetV2 obtuvo una pérdida menor y valores superiores de precisión macro, recall macro y F1 macro. En conjunto, estos resultados indican que, para los datos y la configuración utilizados en este experimento, MobileNetV2 presentó un mejor desempeño que la CNN construida desde cero.

10.2. Resultados por categoría

El análisis por categoría permite identificar diferencias que no se observan completamente en la exactitud global.

Modelo	Categoría	Precisión	Recall	F1
CNN	Tizón temprano	64,95 %	84,00 %	73,26 %
CNN	Tizón tardío	76,47 %	52,00 %	61,90 %
CNN	Saludable	90,91 %	93,33 %	92,11 %
MobileNetV2	Tizón temprano	86,90 %	97,33 %	91,82 %
MobileNetV2	Tizón tardío	96,97 %	85,33 %	90,78 %
MobileNetV2	Saludable	97,33 %	97,33 %	97,33 %

Fuente: archivos de métricas de prueba de ambos modelos.

La CNN presentó su mayor dificultad en la categoría de tizón tardío, con un recall del 52 %. Esto significa que identificó correctamente 39 de las 75 imágenes reales de esa categoría. En consecuencia, las 36 imágenes restantes de tizón tardío fueron clasificadas como alguna de las otras categorías.

Por su parte, MobileNetV2 alcanzó un recall del 85,33 % en tizón tardío, equivalente a 64 imágenes correctamente identificadas de las 75 disponibles. Aunque su resultado es superior, todavía existen errores que deben considerarse.

En la categoría saludable, MobileNetV2 obtuvo un recall del 97,33 %, al identificar correctamente 73 de las 75 imágenes. En tizón temprano también alcanzó un recall del 97,33 %, con 73 imágenes identificadas correctamente.

Estos resultados muestran que MobileNetV2 presentó un desempeño más equilibrado entre las tres categorías. No obstante, las métricas corresponden a un conjunto de prueba específico y no garantizan que se obtengan los mismos resultados con imágenes nuevas tomadas en condiciones agrícolas diferentes.

11. Discusión

La comparación experimental evidencia una diferencia relevante entre los dos enfoques implementados. MobileNetV2 superó a la CNN construida desde cero en todas las métricas generales consideradas.

Una explicación posible es que MobileNetV2 aprovecha representaciones visuales aprendidas durante el preentrenamiento en ImageNet. Estas características pueden facilitar la identificación de patrones como bordes, texturas y estructuras visuales que también aparecen en las imágenes de hojas.

En cambio, la CNN desarrollada desde cero tuvo que aprender las representaciones a partir del conjunto de entrenamiento disponible para este proyecto. Aunque logró una exactitud del 76,44 %, presentó mayores dificultades para distinguir algunas categorías, especialmente el tizón tardío.

El resultado obtenido con MobileNetV2 respalda su elección como modelo principal de la interfaz. Sin embargo, la comparación debe interpretarse considerando que los modelos tienen arquitecturas y estrategias de entrenamiento diferentes. Los resultados no demuestran que MobileNetV2 sea superior en todos los problemas agrícolas, sino que tuvo mejor desempeño bajo las condiciones experimentales evaluadas.

También es necesario considerar que las métricas de validación y prueba no son equivalentes. La exactitud de validación registrada en la última época de MobileNetV2 fue aproximadamente del 90,18 %, mientras que la exactitud final sobre el conjunto de prueba fue del 93,33 %. La diferencia entre ambos valores no implica por sí sola un error; se trata de mediciones realizadas sobre subconjuntos distintos.

En futuras versiones se recomienda ampliar la evaluación con imágenes independientes, revisar el origen y las condiciones de captura de los datos y analizar si existen diferencias importantes entre las imágenes de entrenamiento y las imágenes utilizadas en escenarios reales.

12. Desarrollo de la interfaz AgroVision_AI

Como complemento del entrenamiento de los modelos, se desarrolló una interfaz de usuario que utiliza MobileNetV2 para realizar predicciones sobre imágenes de hojas de tomate.

La aplicación permite seleccionar una imagen, procesarla con las transformaciones requeridas por el modelo y mostrar la categoría predicha junto con información sobre las probabilidades o puntuaciones asociadas a las clases.

La interfaz carga el modelo guardado en la ruta modelos/mobilenetv2_tomate.keras. De esta manera, es posible utilizar los pesos entrenados sin necesidad de volver a ejecutar todo el proceso de entrenamiento cada vez que se inicia la aplicación.

La aplicación también incluye una advertencia sobre el carácter experimental de las predicciones. Esta aclaración es importante porque la clasificación generada por el modelo no constituye un diagnóstico agronómico definitivo.

12.1. Evidencia de funcionamiento de la interfaz

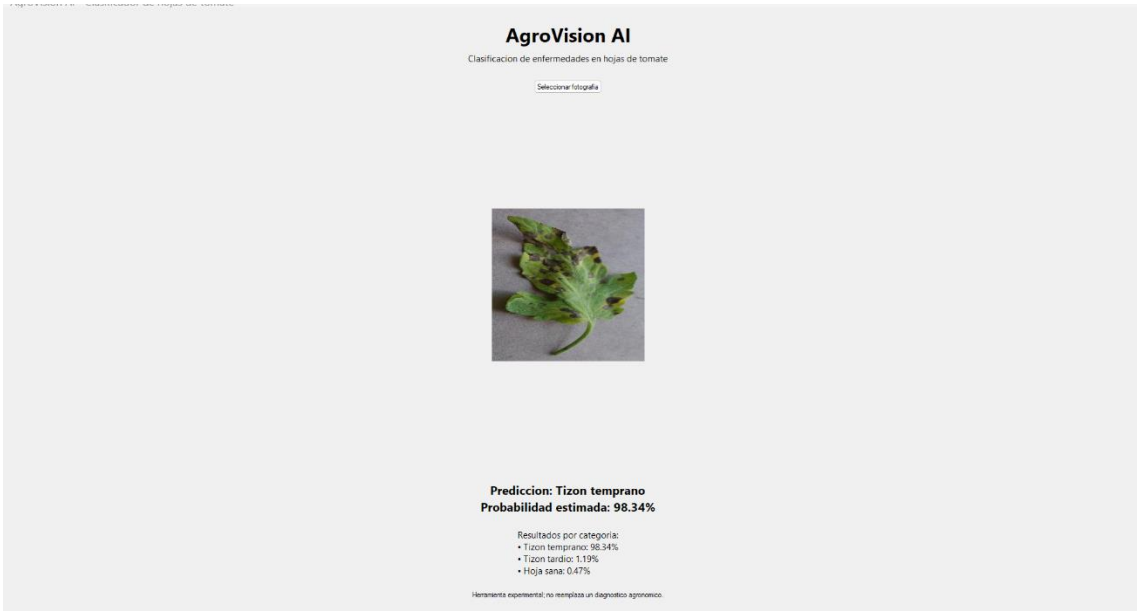


Figura 5. Interfaz de AgroVision_AI durante una prueba de clasificación de una hoja de tomate.
Fuente: captura de pantalla de la aplicación desarrollada para el proyecto.

Esta evidencia permite documentar la presentación de la aplicación y el proceso de interacción con el usuario. La imagen debe mostrar la interfaz real y, si aparece en la captura, la imagen seleccionada para realizar la predicción.

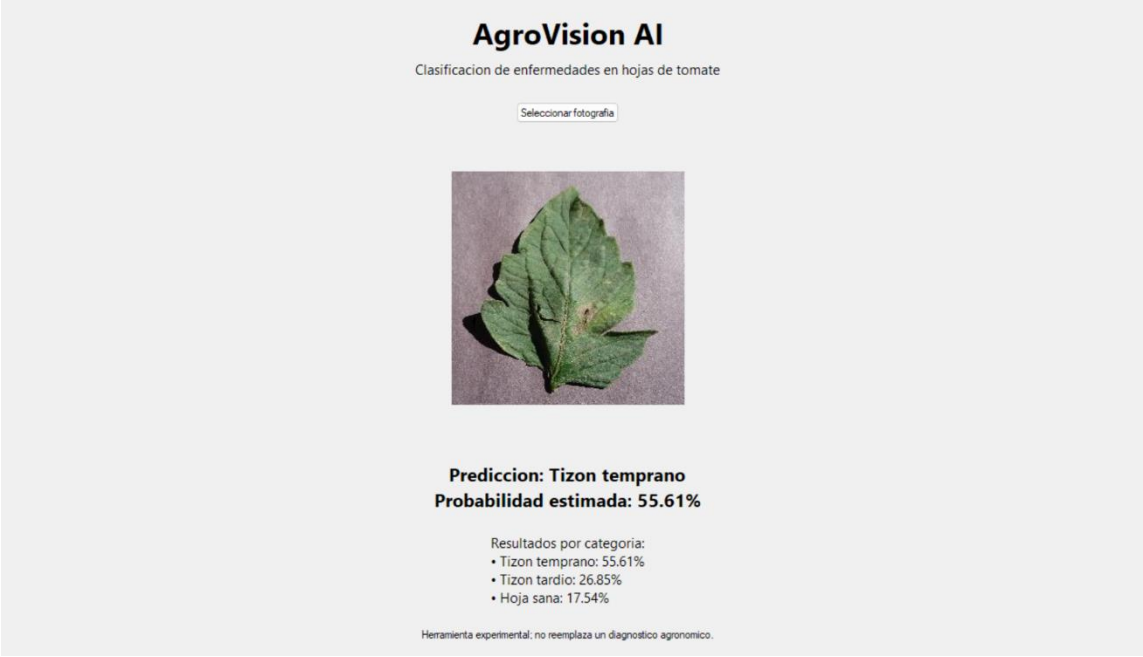


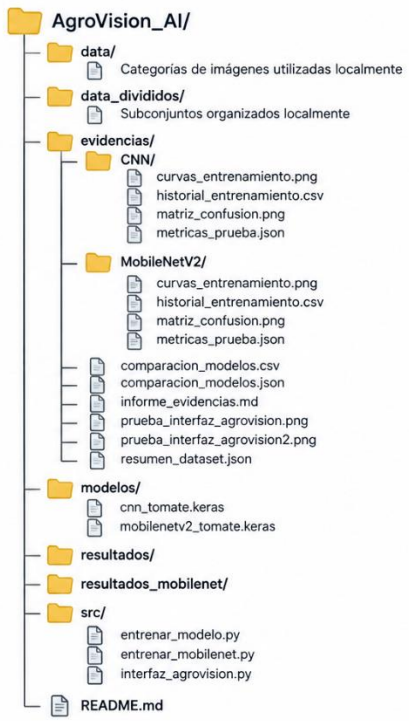
Figura 6. Ejemplo de predicción generada por AgroVision_AI a partir de una imagen de una hoja de tomate.
Fuente: captura de pantalla de la aplicación desarrollada para el proyecto.

Esta segunda evidencia complementa la anterior al mostrar el resultado obtenido durante una prueba de la aplicación. Las predicciones ilustradas corresponden a ejemplos de funcionamiento y no constituyen una validación independiente de la exactitud del sistema en condiciones reales.

13. Estructura y organización del proyecto

El repositorio AgroVision_AI se organiza en carpetas destinadas a separar el código fuente, los modelos entrenados, las evidencias experimentales y los resultados.

La estructura general del proyecto es la siguiente:



Repositorio: https://github.com/juanpablomarquez10-spec/AgroVision_AI

14. Limitaciones del proyecto

Aunque los resultados obtenidos son favorables para MobileNetV2, el proyecto presenta limitaciones que deben considerarse al interpretar las conclusiones.

En primer lugar, la evaluación se realizó sobre un conjunto de 225 imágenes de prueba. Aunque las categorías están equilibradas, este tamaño no representa necesariamente toda la diversidad de hojas, variedades de tomate y condiciones de cultivo que existen en escenarios reales.

En segundo lugar, el desempeño puede verse afectado por factores como la iluminación, el fondo, el enfoque, la orientación de la hoja y la presencia de síntomas diferentes a los observados durante el entrenamiento.

En tercer lugar, el sistema trabaja con tres categorías específicas. Por tanto, no está diseñado para identificar todas las enfermedades del tomate ni para reconocer automáticamente cualquier condición foliar desconocida.

En cuarto lugar, las métricas obtenidas no sustituyen una evaluación con especialistas ni una validación de campo. Un modelo puede obtener buenos resultados sobre imágenes de prueba y presentar dificultades cuando se utiliza con fotografías tomadas en condiciones distintas.

Finalmente, la versión implementada de MobileNetV2 mantiene congelada su base preentrenada. Como trabajo posterior se podría evaluar el ajuste fino de algunas capas, comparar distintas tasas de aprendizaje y analizar si estas modificaciones mejoran el desempeño sin aumentar excesivamente el sobreajuste.

15. Trabajos futuros

Para ampliar el proyecto se proponen las siguientes actividades:

1. Incorporar más imágenes de hojas de tomate procedentes de diferentes condiciones de captura y cultivo.
2. Validar el sistema con fotografías independientes de las utilizadas durante el entrenamiento.
3. Investigar el origen, la licencia y las características del conjunto de datos para documentar adecuadamente su procedencia.
4. Evaluar técnicas de ajuste fino de MobileNetV2 y comparar sus resultados con la versión actual.
5. Analizar con mayor detalle los errores entre las categorías de tizón temprano y tizón tardío.
6. Incorporar pruebas sistemáticas con imágenes borrosas, fondos complejos y variaciones de iluminación.
7. Mejorar la interfaz para facilitar la carga de imágenes y la interpretación de las predicciones.
8. Registrar las versiones de las bibliotecas, los parámetros de entrenamiento y las condiciones necesarias para reproducir los resultados.
9. Realizar una evaluación con apoyo de especialistas en sanidad vegetal antes de plantear un uso práctico en agricultura.

16. Conclusiones

El proyecto AgroVision_AI permitió desarrollar un sistema experimental de clasificación de imágenes de hojas de tomate mediante técnicas de aprendizaje profundo. Se preparó un conjunto de datos con tres categorías y se implementaron dos modelos con estrategias diferentes: una CNN construida desde cero y MobileNetV2 con aprendizaje por transferencia.

Los resultados de prueba mostraron que la CNN alcanzó una exactitud del 76,44 %, mientras que MobileNetV2 obtuvo un 93,33 %. La diferencia de 16,89 puntos porcentuales favoreció al modelo preentrenado. Asimismo, MobileNetV2 presentó mejores resultados en precisión macro, recall macro y puntuación F1 macro.

El análisis por categoría evidenció que la CNN tuvo dificultades para reconocer las imágenes de tizón tardío, con un recall del 52 %. MobileNetV2 mejoró este resultado hasta el 85,33 %, aunque todavía presentó

errores de clasificación. Esto demuestra la importancia de examinar las métricas por clase y no depender únicamente de la exactitud global.

También se desarrolló una interfaz que permite cargar imágenes y consultar las predicciones de MobileNetV2. Esta integración demuestra cómo un modelo entrenado puede incorporarse a una aplicación sencilla para facilitar su evaluación y uso experimental.

En conclusión, bajo las condiciones evaluadas, MobileNetV2 fue la alternativa con mejor desempeño para el problema planteado. No obstante, los resultados deben interpretarse dentro del alcance del conjunto de datos utilizado. Antes de considerar el sistema para aplicaciones agrícolas reales, será necesario ampliar las pruebas, evaluar imágenes de diferentes condiciones y contar con validación especializada.

El desarrollo constituye una base académica para continuar investigando el uso de redes neuronales convolucionales y aprendizaje por transferencia en tareas de clasificación de imágenes agrícolas.

17. Referencias bibliográficas

Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., y Adam, H. (2017). *MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications*. arXiv. https://arxiv.org/abs/1704.04861

Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., y Chen, L.-C. (2018). MobileNetV2: Inverted Residuals and Linear Bottlenecks. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. https://doi.org/10.1109/CVPR.2018.00474

TensorFlow. (s. f.). *TensorFlow documentation*. https://www.tensorflow.org/

Keras. (s. f.). *Keras documentation*. https://keras.io/

18. Repositorio y evidencias

El código fuente, los modelos entrenados y las evidencias del proyecto se organizan en el repositorio de AgroVision_AI:

https://github.com/juanpablomarquez10-spec/AgroVision_AI

Entre los archivos de evidencia se incluyen:

- Resumen de la distribución del conjunto de datos.
- Historiales de entrenamiento de ambos modelos.
- Curvas de exactitud y pérdida.
- Matrices de confusión.
- Métricas de evaluación sobre el conjunto de prueba.
- Tabla de comparación entre CNN y MobileNetV2.
- Capturas de la interfaz y ejemplos de predicción.

Estos archivos permiten relacionar los resultados presentados en el informe con los registros generados durante el desarrollo. La disponibilidad de las evidencias facilita la revisión académica y contribuye a la transparencia del proceso experimental.